

Modelos de Regressao e Classificacao Linear

Lucas Barroso Sa 2426651

Lucas Peixoto Magalhaes 2310402

Samuel De Francesco Lima 2314993

Abstract

Este documento apresenta o desenvolvimento e a avaliacao de modelos preditivos baseados no metodo de Minimos Quadrados Ordinarios (MQO) para uma tarefa de regressao do PIB da China e para a classificacao de expressoes faciais. O estudo de classificacao utiliza sinais de eletromiografia captados por sensores em dois musculos faciais. A metodologia abrange a implementacao dos estimadores tradicional, regularizado e polinomial. A regressao foi avaliada por Random Subsampling e a classificacao por simulacoes de Monte Carlo. Observacao: simbolos, caracteres especiais e equacoes matematicas foram omitidos do titulo e do resumo em conformidade com as diretrizes do template.

I. Introduction

O presente trabalho e composto por duas etapas. A primeira e um sistema de predicao quantitativa do PIB da China, usando o ano como variavel regressora. A segunda aborda o desenvolvimento de um sistema de predicao qualitativa focado no reconhecimento de padroes em sinais de eletromiografia (EMG). A base de dados de classificacao e composta por 50.000 amostras captadas a uma taxa de amostragem de 1 kHz. Os dados sao oriundos de dois sensores posicionados no musculo Corrugador do Supercilio e no Zigomatico Maior. O objetivo e categorizar cinco expressoes faciais: neutro, sorriso, sobrancelhas levantadas, surpreso e rabugento.

II. Methodology

Na classificacao, o vetor de rotulos Y foi transformado em uma matriz binaria por one-hot encoding, com dimensao N por C . Os modelos avaliados foram o MQO tradicional, o MQO regularizado (Tikhonov) e o MQO polinomial. A validacao usou amostragem aleatoria (Monte Carlo) com $R = 500$ rodadas, 80% dos dados para treino e 20% para teste. A medida de desempenho foi a acuracia.

Na regressao, o arquivo china_gdp.csv foi organizado numa matriz X de dimensao N por p e num vetor y de dimensao N por 1. Os modelos foram o MQO tradicional, o MQO regularizado com λ igual a 0, 0,25, 0,5, 0,75 e 1, e a regressao polinomial via MQO. O grau q foi escolhido por poda, olhando o R^2 . A validacao dessa etapa tambem teve $R = 500$ rodadas, com 80% para treino e 20% para teste. As medidas usadas foram MSE e R^2 . Todos os modelos estimam o intercepto.

III. Results and Discussion

A. Analise visual e separacao de classes

As figuras foram posicionadas preferencialmente no topo ou na base da pagina. A Fig. 1 mostra o grafico de espalhamento das expressoes faciais.




Fig. 1. Gráfico de espalhamento evidenciando a distribuição das expressões faciais captadas pelos sensores EMG.

A análise inicial evidenciou sobreposição entre as nuvens de pontos no espaço bidimensional (Sensores 1 e 2). Essa característica fundamenta a hipótese de que as classes não são linearmente separáveis. Consequentemente, um modelo de fronteira linear simples (MQO tradicional) tende a apresentar taxa de erro mais alta.

B. Seleção do hiperparâmetro polinomial (classificação)

A definição do grau q baseou-se no compromisso entre acurácia e tempo de estimação. Nos testes, $q = 1$ ficou com acurácia 0,7241. O grau 2 subiu para 0,9482. O grau 3 caiu para 0,7465, sem justificar o aumento de custo. Por isso o script fixou $q = 2$.

C. Avaliação de desempenho (simulação de Monte Carlo)

Os resultados estatísticos das 500 rodadas de validação da classificação estão na Tabela I.

Tabela I. Acurácia nas 500 rodadas de classificação.

Modelos	Média	Desvio-Padrão	Maior Valor	Menor Valor
MQO Tradicional	0.7239	0.0063	0.7429	0.7066
MQO Regularizado (0,5)	0.7241	0.0067	0.7452	0.6966
MQO Polinomial	0.9482	0.0022	0.9544	0.9423

A comparação das médias confirma que a expansão polinomial superou os modelos puramente lineares. O baixo desvio-padrão ao longo das 500 iterações atesta que as estimativas são estáveis.

D. Tarefa de regressão

A Fig. 2 mostra o gráfico de espalhamento do PIB da China em função do ano.




Fig. 2. Gráfico de espalhamento do PIB da China em função do ano.

A análise inicial mostrou um crescimento lento nas primeiras décadas e uma aceleração bem mais forte a partir dos anos 1990. Esse formato não parece uma reta. Por isso um modelo só linear deve errar mais, principalmente nos anos mais recentes, quando o PIB sobe rápido.

E. Seleção do grau polinomial (regressão)

O hiperparâmetro q foi escolhido por poda, comparando o R^2 . O grau 1 ficou com R^2 igual a 0,5240. O grau 2 subiu para 0,8424, o grau 3 para 0,9645 e o grau 4 para 0,9932. No grau 5 o ganho ficou abaixo de 0,5%, então o q foi fixado em 4.

F. Avaliacao de desempenho (Random Subsampling)

Os resultados estatisticos das 500 rodadas de validacao da regressao estao sumarizados na Tabela II (R2) e na Tabela III (MSE).

Tabela II. R2 nas 500 rodadas de regressao.

Modelos	Media	Desvio-Padiao	Maior Valor	Menor Valor
Polinomial	0.9488	0.2232	0.9986	-3.3474
MQO tradicional	-0.9192	5.7781	0.7887	-95.421
MQO Reg. (0,25)	-0.5668	4.4074	0.7626	-69.010
MQO Reg. (0,5)	-0.6768	4.5751	0.7573	-65.611
MQO Reg. (0,75)	-0.3907	3.2315	0.7489	-38.033
MQO Reg. (1)	-0.3337	3.5878	0.7759	-67.862

Tabela III. MSE nas 500 rodadas de regressao.

Modelos	Media	Desvio-Padiao	Maior Valor	Menor Valor
Polinomial	5.53e22	3.09e22	4.81e23	5.37e21
MQO tradicional	3.35e24	1.99e24	1.26e25	7.82e23
MQO Reg. (0,25)	3.37e24	2.17e24	1.49e25	6.61e23
MQO Reg. (0,5)	3.23e24	2.10e24	1.55e25	6.38e23
MQO Reg. (0,75)	3.24e24	2.29e24	1.49e25	6.34e23
MQO Reg. (1)	3.45e24	2.62e24	1.49e25	5.27e23

A media do R2 do polinomio ficou em 0,9488, bem acima dos modelos lineares. O MQO tradicional e o regularizado chegaram a media negativa. Isso acontece porque a serie e pequena (55 amostras) e o PIB cresce de um jeito bem curvo: em alguns sorteios o teste pega logo os anos mais altos e a reta nao acompanha. Os valores de lambda testados no MQO regularizado nao mudaram o resultado de forma relevante em relacao ao MQO tradicional.

IV. Conclusao

A aplicacao da familia de estimadores MQO demonstrou-se uma abordagem solida para a classificacao de sinais eletromiograficos faciais, desde que as limitacoes espaciais dos dados sejam respeitadas. A incapacidade de separacao linear direta foi solucionada pela elevacao dimensional do metodo polinomial. Na regressao do PIB aconteceu a mesma coisa: o MQO linear nao acompanhou a curva e o polinomio com $q = 4$ ficou com o melhor R2 medio. A validacao estruturada via Monte Carlo e Random Subsampling conferiu alta confiabilidade as metricas finais.